

CNT3054

3주차 2강

JTBC 뉴스룸 유튜브 댓글 수집 실습

YouTube API 발급, 댓글 수집과 Supabase 저장

문화콘텐츠와 자연어처리 · CNT3054 · 장수빈 111usion@skku.edu

오늘 실습 순서

1

원본 저장소의 코드 구조

data_scrape.py가 데이터를 가져오고 저장하는 순서

2

Google API 키 발급

프로젝트 생성 · API 사용 설정 · 키 저장

3

영상 1편의 댓글 수집

연결 확인 · API 요청 · JSON 응답 읽기

4

반복 수집과 결과 확인

다음 페이지 · 중복 ID · CSV와 수집 로그

5

Supabase 연결과 저장

프로젝트 생성 · DB 연결 · 테이블과 댓글 저장

1. 실습 범위

이번에 수집할 데이터

항목	이번 실습의 기준
대상	JTBC 뉴스룸 영상 1편
분석 단위	최상위 댓글 1개
첫 실행	시간순 첫 페이지, 최대 100개 요청
저장	원문 CSV + 수집 조건 JSON + Supabase DB

답글 본문은 별도 조회가 필요하다. 실제로 받은 범위를 결과와 함께 기록한다.

저장소에서 읽을 파일

파일	역할
data_scrape.py	재생목록 조회, 댓글 수집, DB 저장
stt.py / stt_resume.py	음성에서 뉴스 대본 추출
llm-ev.py / ev-run.py	수집 이후의 분석·평가
apitest.py	OpenAI API 연결 테스트
main.py	인사말 출력

data_scrape.py의 실행 흐름

1

`get_playlist_videos(playlist_id)`

재생목록을 순회하고 기간에 맞는 영상 목록 반환

2

`psycopg2.connect() / create_tables()`

Supabase의 PostgreSQL에 연결하고 테이블 생성

3

영상별 `get_video_comments() / get_video_transcript()`

댓글 리스트와 자막 결과를 영상 딕셔너리에 추가

4

`insert_data(conn, [video])`

videos와 comments에 저장한 뒤 마지막에 연결 종료

원본 코드와 수업용 코드

구분	원본 data_scrape.py	수업용 코드
영상 입력	재생목록 + 날짜 필터	영상 URL 또는 ID 1개
댓글 조회	한 페이지, 최대 100개	페이지 상한까지 반복
저장 위치	Supabase PostgreSQL	CSV·JSON 저장 후 Supabase 업로드
중복 확인	댓글 ID 중복 처리 없음	실행 중 ID 확인 + DB 기본키
추가 처리	자막 조회 시도	최상위 댓글 수집

이후 실행 명령은 함께 제공한 수업용 ZIP을 기준으로 한다.

Google Cloud 프로젝트 생성

1 Google Cloud Console 로그인
본인의 Google 계정 사용

2 상단 프로젝트 선택 메뉴 열기
새 프로젝트 선택

3 프로젝트 이름 입력 후 만들기
예시: cnt3054-youtube

4 생성한 프로젝트 선택
다음 API 설정도 같은 프로젝트에서 진행

YouTube Data API v3 사용 설정

1

API 및 서비스 메뉴
라이브러리 열기

2

YouTube Data API v3 검색
검색 결과에서 같은 이름의 API 선택

3

사용 버튼 클릭
사용 설정된 API 및 서비스 목록에서 확인

프로젝트 이름을 다시 확인한다. API를 켜 프로젝트와 키를 만든 프로젝트가 같아야 한다.

API 키 생성과 제한 설정

- 1 API 및 서비스 > 사용자 인증 정보
사용자 인증 정보 만들기 > API 키
- 2 API 제한사항: 키 제한
YouTube Data API v3만 선택
- 3 애플리케이션 제한사항
개인 PC 실습은 없음. 웹사이트 제한은 로컬 Python과 맞지 않음
- 4 키 문자열 복사
서비스 계정 연결은 선택하지 않고 .env에 저장

API 키를 읽는 .env 파일

.env 파일 내용

```
google_cloud_api_key=본인이_발급받은_키
```

파일 위치와 이름

collect_comments.py와 같은 폴더
파일명은 .env, 변수 이름은 대소문자까지 동일하게

.env는 제출하거나 GitHub에 올리지 않는다. 노출한 키는 폐기하고 새 키로 교체한다.

실습 파일과 VS Code

파일	용도
collect_comments.py	이번 실습 실행 파일
requirements.txt	필요한 패키지 목록
.env.example / .gitignore	키 입력 양식 / Git 제외 목록
demo_pages.json	API 없이 사용할 가상 응답
upload_supabase.py / setup_tables.sql	Supabase 연결·저장 / 테이블 생성 SQL
README.md	설치·실행·오류 해결 안내

ZIP 해제 후 jtbc_comments_lab 폴더 열기. VS Code 터미널도 이 폴더에서 실행한다.

가상환경과 패키지 설치

Windows PowerShell

```
py -3.11 -m venv .venv  
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
```

macOS 터미널

```
python3 -m venv .venv  
./venv/bin/python -m pip install -r requirements.txt
```

VS Code의 Python: Select Interpreter에서 .venv 선택

설치 패키지: google-api-python-client, python-dotenv, psycopg2-binary. Python 3.11 이상 기준.

JTBC 뉴스룸 영상 선택

1

원본 코드의 재생목록 열기

JTBC 뉴스룸 영상인지 채널과 제목 확인

2

영상 1편 선택

전체 방송인지 개별 리포트인지 기록

3

영상 URL 복사

재생목록 URL이 아니라 영상 재생 페이지의 주소

원본 코드에 지정된 재생목록 열기

실습 전에 영상 공개 여부와 댓글 활성화 여부를 확인한다.

API 연결과 영상 확인

Windows 실행 예시

```
.\.venv\Scripts\python.exe collect_comments.py  
--video "영상_URL" --check
```

위 명령은 줄바꿈 없이 한 줄로 입력한다.

성공하면 보이는 내용

채널: 선택한 영상의 채널명 / 제목: 영상 제목
API 연결 및 영상 조회 성공

수업용 코드의 함수 구조

함수	입력	출력 또는 역할
parse_video_id()	영상 URL 또는 ID	video_id
make_youtube_client()	.env의 키	YouTube 요청 객체
get_video_info()	요청 객체 + video_id	제목·채널 정보
collect_comments()	영상 ID + 페이지 상한	댓글 행 목록 + 로그
parse_comment()	댓글 스레드 1개	CSV 한 행의 딕셔너리
save_results()	댓글 목록 + 수집 조건	comments.csv + collection_log.json

main()이 입력을 확인하고 각 함수의 호출 순서를 관리한다.

환경변수와 API 클라이언트

make_youtube_client()에서 하는 일

```
load_dotenv(BASE / ".env")
api_key = os.getenv("google_cloud_api_key")

youtube = build(
    "youtube", "v3", developerKey=api_key
)
```

키는 어떤 프로젝트의 요청인지 식별한다. 댓글 조회는 다음 함수에서 실행한다.

설명용 발췌. 실제 파일에는 키 누락 확인과 통신 타임아웃 설정도 포함되어 있다.

댓글 조회 요청

```
request = youtube.commentThreads().list(  
    part="snippet",  
    videoId=video_id,  
    maxResults=100,  
    order="time",  
    textFormat="plainText",  
    pageToken=page_token  
)  
response = request.execute()
```

list(...)는 요청 조건을 구성하고, execute()가 실제 요청을 보낸다.

요청 조건의 의미

매개변수	값	의미
part	snippet	기본 댓글 정보 묶음
videoid	영상 ID	어느 영상의 댓글인지
maxResults	100	한 페이지에서 요청할 최대 개수
order	time	시간순 조회
textFormat	plainText	HTML 대신 일반 텍스트
pageToken	없음 / 다음 토큰	첫 페이지 / 이어지는 페이지

JSON 응답의 중첩 구조

```
{
  "items": [{
    "snippet": {
      "topLevelComment": {
        "id": "DEMO_COMMENT_1",
        "snippet": {"textDisplay": "추가 설명이 궁금해요."}
      },
      "totalReplyCount": 2
    }
  ]},
  "nextPageToken": "다음_페이지_토큰"
}
```

댓글 하나를 한 행으로 변환

parse_comment()의 접근 순서

```
top = item["snippet"]["topLevelComment"]
comment = top["snippet"]

row = {
    "comment_id": top["id"],
    "text_raw": comment["textDisplay"],
    "like_count": comment["likeCount"]
}
```

댓글 1개 = 딕셔너리 1개. 이 딕셔너리를 rows 리스트에 차례로 추가한다.

다음 페이지를 받는 반복문

collect_comments()의 반복 구조

```
page_token = None
for _ in range(max_pages):
    # pageToken=page_token으로 요청하고 응답 처리
    page_token = response.get("nextPageToken")
    if not page_token:
        break
```

응답 이름은 nextPageToken, 다음 요청의 매개변수 이름은 pageToken이다.

수집 개수와 종료 이유

설정 또는 로그	해석
--max-pages 1	최대 1페이지 요청
--max-pages 3	최대 3페이지 요청, 반드시 300개는 아님
no_next_page	응답에 다음 페이지 토큰이 없음
page_limit	설정한 페이지 상한에 도달
error	조회 중 오류. 그 전에 받은 행만 저장

has_more=true이면 다음 페이지가 남아 있다. 100개 수집과 전체 수집은 구분한다.

댓글 ID로 중복 확인

이번 실행에서 본 ID

```
if row["comment_id"] in seen:  
    continue  
seen.add(row["comment_id"])  
rows.append(row)
```

같은 ID + 같은 본문: 반복 수집 여부 확인
다른 ID + 같은 본문: 각각의 댓글로 유지

CSV에 저장할 열

열	내용
video_id / comment_id	영상과 댓글을 구분하는 ID
text_raw	API에서 받은 본문
published_at	댓글 작성 시각
like_count / reply_count	수집 시점의 좋아요 수 / 답글 수
collected_at	이번 수집 실행 시각, UTC

한 행은 최상위 댓글 1개다. 영상 공개일과 댓글 작성일을 구분한다.

CSV와 수집 로그 저장

save_results()의 CSV 저장 부분

```
with csv_path.open(
    "w", encoding="utf-8-sig", newline=""
) as f:
    writer = csv.DictWriter(f, fieldnames=COLUMNS)
    writer.writeheader()
    writer.writerows(rows)
```

comments.csv: 원문과 메타데이터
collection_log.json: 수집 조건, 페이지 수, 종료 이유

댓글 수집 실행

Windows: 첫 페이지 수집

```
.\.venv\Scripts\python.exe collect_comments.py  
--video "영상_URL" --max-pages 1
```

macOS: 첫 페이지 수집

```
./venv/bin/python collect_comments.py  
--video "영상_URL" --max-pages 1
```

결과 파일 확인

- 1 output 폴더 안의 이번 실행 폴더
comments.csv와 collection_log.json 확인
- 2 행 수와 본문 확인
한글, 줄바꿈, 빈 본문, 같은 댓글 ID 점검
- 3 수집 조건 확인
order, max_pages, pages_received, stop_reason
- 4 수집 범위 설명
top_level_only, 답글 본문 없음, 댓글 작성일 필터 없음

API 없이 코드 흐름 연습

```
python collect_comments.py --demo --max-pages 2
```

실행 결과

```
가상 응답 2페이지, 댓글 4개 저장  
stop_reason: no_next_page  
mode: DEMO_FICTIONAL
```

demo_pages.json은 수업용 가상 데이터다. 실제 JTBC 댓글과 구분한다.

자주 발생하는 오류

메시지·상태	확인할 내용
ModuleNotFoundError	설치한 가상환경의 Python으로 실행했는가?
키 누락 / keyInvalid	올바른 .env 위치, 변수 이름, 키 문자열인가?
accessNotConfigured / 제한 관련 403	같은 프로젝트의 API 사용 설정과 키 제한 확인
commentsDisabled	댓글이 활성화된 다른 영상 선택
quotaExceeded	프로젝트 할당량 확인 후 수집 중단
0행 저장	로그에서 정상 빈 결과와 요청 오류 구분

Supabase 프로젝트 생성

- 1 Supabase 가입 또는 로그인
supabase.com/dashboard에서 본인 계정 사용
- 2 Organization 선택 또는 생성
수업용 Free 플랜의 조직 선택
- 3 New project
이름 예시: cnt3054-jtbc / Database password 설정
- 4 지역 선택 후 프로젝트 생성
한국과 가까운 사용 가능 지역 선택, 준비 완료까지 대기

두 서비스의 연결 정보

구분	YouTube	Supabase PostgreSQL
하는 일	영상과 댓글 조회	수집한 영상·댓글 저장
인증 정보	Google API 키	DB 비밀번호가 포함된 연결 URI
환경변수	google_cloud_api_key	SUPABASE_CONNECTION_STRING
파이썬 패키지	google-api-python-client	psycopg2-binary

Supabase의 Project URL이나 API 키는 이 실습의 DB 연결 문자열을 대신하지 않는다.

Connect에서 연결 문자열 확인

- 1 프로젝트 상단 Connect
연결 형식은 URI 선택
- 2 연결 방식: Session pooler
IPv4에서도 사용할 수 있는 연결 방식
- 3 사용자명과 포트 확인
보통 postgres.프로젝트참조값 / 포트 5432
- 4 본인 프로젝트의 URI 복사
호스트·사용자명을 직접 조합하지 않고 콘솔 값 사용

Transaction pooler의 포트 6543과 구분한다. 비밀번호는 다음 단계에서 입력한다.

DB 연결 정보를 .env에 저장

추가 패키지 설치 후 실행: Windows

```
.\.venv\Scripts\python.exe -m pip install -r requirements.txt  
.\.venv\Scripts\python.exe upload_supabase.py --configure
```

1

Connect에서 복사한 URI 붙여넣기

입력 글자가 보이지 않아도 정상. 붙여넣은 뒤 Enter

2

Database password 입력

프로젝트 생성 때 정한 비밀번호. 특수문자 인코딩은 코드가 처리

데이터베이스 연결 확인

```
python upload_supabase.py --check-db
```

connect_db()와 확인 쿼리

```
conn = psycopg2.connect(
    connection_string,
    sslmode="require", connect_timeout=10
)
cur.execute("SELECT current_database(), current_user")
```

영상 테이블과 댓글 테이블

테이블	한 행의 의미	주요 열
lab_videos	영상 1편	video_id, title, channel_title, is_demo
lab_comments	최상위 댓글 1개	comment_id, video_id, text_raw, 시각·좋아요 수

기본키: lab_videos.video_id / lab_comments.comment_id
외래키: lab_comments.video_id가 lab_videos.video_id를 참조

수업용 테이블 생성

```
python upload_supabase.py --init-db
```

1

setup_tables.sql 실행

lab_videos와 lab_comments 생성

2

기본키와 외래키 설정

댓글 ID 중복과 존재하지 않는 영상 참조 방지

3

Table Editor에서 확인

public 스키마의 두 테이블이 보이면 준비 완료

수집한 CSV를 Supabase에 저장

Windows

```
.\.venv\Scripts\python.exe upload_supabase.py  
--folder "수집폴더_경로"
```

macOS

```
./venv/bin/python upload_supabase.py  
--folder "수집폴더_경로"
```

수집폴더 안의 comments.csv와 collection_log.json을 읽어 데이터베이스에 저장한다.

DB 저장 코드의 실행 순서

- 1 `read_batch(folder)`
CSV와 로그 읽기, video_id·자료형 확인
- 2 `connect_db()`
본인의 Supabase PostgreSQL 연결
- 3 `insert_batch(conn, metadata, rows)`
영상 먼저 저장, 댓글 묶음 저장
- 4 `commit / rollback / close`
두 테이블 저장에 성공하면 확정, 오류 시 취소, 연결 종료

ON CONFLICT (comment_id) DO NOTHING

Supabase에서 저장 결과 확인

SQL Editor의 새 쿼리

```
SELECT v.video_id, v.title, v.is_demo,  
       count(c.comment_id) AS comments  
FROM public.lab_videos AS v  
LEFT JOIN public.lab_comments AS c  
  ON c.video_id = v.video_id  
GROUP BY v.video_id, v.title, v.is_demo;
```

같은 수집 폴더를 다시 올려도 댓글 ID가 같으면 총 행 수는 늘어나지 않는다.

Supabase 연결 오류 확인

상황 또는 오류	확인할 내용
비밀번호 입력이 안 보임	--configure는 숨김 입력. 입력 후 Enter
인증 실패 / 28P01	Database password 확인 후 --configure 재실행
Tenant or user not found	콘솔에서 복사한 호스트와 postgres.프로젝트참조값
연결 시간 초과 / 네트워크 오류	프로젝트 상태, Session pooler, 네트워크의 5432 허용
테이블 없음 / 42P01	같은 프로젝트에서 --init-db 실행
권한 없음 / 42501	Connect에서 복사한 본인 DB 연결 정보 확인

팀별 적용과 제출

1

뉴스룸 영상 최근 1주일 댓글 수집

“수집한 댓글로 무엇을 할 수 있을까?”에 대한 생각과 실행 방법을 작성해서 9월 20일까지 제출

2

코드 설명

execute(), nextPageToken, comment_id의 역할을 보고서 방법론 파트에 포함

3

제출 파일

CSV·로그와 DB 건수 조회 결과, 중복 저장 방지 설명. GitHub Link 및 supabase link 보고서에 각주로 포함

확장: 재생목록과 답글

확장할 내용	확인할 코드와 조건
여러 영상 수집	<code>get_playlist_videos()</code> 의 <code>video_id</code> 목록 반복
영상 날짜 기준	<code>playlistItems</code> 의 추가 시각과 영상 공개 시각 구분
기간의 마지막 날	시작 이상, 다음 날 00:00 미만으로 범위 설정
답글 본문 수집	<code>comments.list(parentId=댓글 ID)</code> 와 페이지 반복

수집 대상을 늘릴 때는 API 호출 횟수와 데이터의 포함 기준도 함께 바뀐다.

참고 자료

원본 저장소와 수집 코드

github.com/111usionBin/jtbc-2025

Google API 시작 안내

developers.google.com/youtube/v3/getting-started

API 키 생성·제한

docs.cloud.google.com/docs/authentication/api-keys

댓글 요청과 페이지네이션

developers.google.com/youtube/v3/docs/commentThreads/list

댓글 응답 구조

developers.google.com/youtube/v3/docs/commentThreads

답글 조회

developers.google.com/youtube/v3/docs/comments/list

재생목록의 날짜 필드

developers.google.com/youtube/v3/docs/playlistItems

Supabase 참고 자료

프로젝트 생성

supabase.com/dashboard

PostgreSQL 연결 안내

supabase.com/docs/guides/database/connecting-to-postgres

테이블과 데이터

supabase.com/docs/guides/database/tables

RLS와 접근 권한

supabase.com/docs/guides/database/postgres/row-level-security

psycopg2 사용법

psycopg.org/docs/usage.html